FIAP / GLOBAL SOLUTION / 2º SEMESTRE DE 2026

Fábrica de Corpus CitizenTech

Enchentes e deslizamentos
Da cartilha pública aos dados de treino e teste.

88	112	30	20
TRECHOS	PARES QA	DIÁLOGOS	TESTES

EQUIPE

Luiz Henrique Poss
Luis Filipe Chaves Amorim
Felipe Stefani Honorato

Para quem é a fábrica?

O recorte vai do preparo comunitário à evacuação e aos cuidados depois da inundação.

O problema de Joana

Joana é uma moradora fictícia de um bairro com córrego e encosta. Em dias de chuva, acessa a internet pelo celular e precisa decidir se deve se afastar, onde procurar orientação e a quem pedir socorro. As respostas devem caber em uma leitura rápida e indicar o próximo passo.

ODS 11 · Meta 11.5

O projeto ajuda a tornar orientações sobre desastres ligados à água mais fáceis de localizar, com atenção a moradores de áreas vulneráveis. ONU Brasil.

05 FONTES PÚBLICAS

01 **Periferia sem risco**
Ministério das Cidades · Secretaria Nacional de Periferias · 2024 · Abrir fonte

02 **Cartilha para ações comunitárias de redução de risco**
Ministério das Cidades · Secretaria Nacional de Periferias · 2024 · Abrir fonte

03 **Cartilha de orientação no alerta de chuvas intensas**
Ministério da Saúde · 2017 · Abrir fonte

04 **Guia de preparação e resposta por inundação**
Ministério da Saúde · 2017 · Abrir fonte

05 **Canais de emergência**
Ministério das Comunicações · 2026-09-11 · Abrir fonte

103 páginas físicas em quatro PDFs e uma página HTML. A data é a da edição ou publicação. O manifesto guarda URLs, seções e hashes das cópias usadas.

Da fonte ao JSONL

O Python reproduz a edição com documentos, âncoras e tokenizador locais.

01

Ingerir

PDF, TXT, DOCX, HTML ou texto colado. PDF mantém página física; DOCX e HTML preservam cabeçalhos de seção.

02

Limpar

Remove margens repetidas, numeração, URLs soltas e artefatos gráficos. Une palavras quebradas no fim da linha.

03

Normalizar e mascarar

Padroniza UTF-8/NFC, espaços e aspas. Preserva acentos e pontuação. Aplica regex e NER antes da saída.

04

Segmentar

Agrupa frases e parágrafos em 256 a 512 tokens do Qwen2.5-0.5B-Instruct. Reequilibra a cauda quando possível.

05

Ancorar e exportar

Busca o apoio literal nos documentos limpos, remove duplicatas e valida o teste congelado antes de exportar.

FORMA SE TREINA. FATO SE CONSULTA.

Estável · comportamento

Escrever com clareza, usar o histórico e encaminhar quando falta informação. Categorias e conceitos gerais ajudam no vocabulário. O treino usa contexto de apoio para ligar a resposta ao documento.

Volátil · consulta

Abrigos abertos, vagas, vias liberadas, alertas, horários, contatos locais e protocolos vigentes dependem da região e do momento. O RAG deve buscar uma fonte datada e consultar a autoridade atual quando necessário.

O que sai dos dados

A mesma rotina usada nas fontes processa a ficha fictícia antes da exportação.

01 / FICHA ORIGINAL

```
Nome: Aurora de Papel Fictícia
CPF: 000.000.000-00
E-mail: aurora@exemplo.invalid
Telefone: +55 (00) 90000-0000
```

02 / FICHA MASCARADA

```
Nome: [NOME]
CPF: [CPF]
E-mail: [EMAIL]
Telefone: [TELEFONE]
```

O relato de orientação sobre chuva e a menção à Defesa Civil foram preservados. Os identificadores foram inventados para esta demonstração. A ficha fica fora dos quatro JSONL.

Regras e exceções

Regex mascara CPF, e-mail e telefone. O spaCy marca entidades de pessoa, com regra extra para campos de nome. Instituições e títulos como Defesa Civil, Fiocruz e Lei Maria da Penha são preservados. O manifesto lista exceções verificadas, como PNRS e Tétano.

Minimização e guarda

O material vem de fontes oficiais. Capas com créditos, referências e dados de contato desnecessários são excluídos ou filtrados. A ferramenta não cria tabela de correspondência e descarta os uploads temporários. A evidência de antes e depois contém apenas a ficha sintética.

O reconhecimento de nomes pode errar, principalmente com siglas, nomes incomuns e leitura imperfeita de PDFs. Novas fontes exigem revisão de privacidade antes da publicação.

O que a execução mostrou

A saída separa texto, perguntas e respostas, conversa e avaliação.

Corpus	Exemplos	Tokens méd.	Duplicatas	Língua real
Texto puro	88	292,9	0	-
Perguntas e respostas	112	77,5	0	56/112
Conversacional	30	264,8	0	30/60
Teste separado	20	46,2	0	10/20

Texto puro: 265 a 499 tokens. A média conta o conteúdo textual de cada formato. Cinco exemplos de cada corpus estão em **qualidade.json**. A taxa de língua real foi de 50% nos três conjuntos com perguntas.

20 de 20 pares fiéis na conferência assistida

Uma amostra com semente 1126 foi comparada com os trechos de apoio. Os 20 pares conferidos ficaram dentro do que as passagens sustentam. O script também checa automaticamente a presença de todas as âncoras. A revisão humana da amostra permanece pendente em revisao.csv.

13 diálogos de limite

Quatro recusas fora do tema, quatro encaminhamentos e cinco urgências. Os 30 diálogos têm duas trocas. O teste inclui nove perguntas diretas, quatro fora do tema, quatro urgências e três pegadinhas. A comparação normalizada detectou zero perguntas de teste no treino.

EVIDÊNCIA DE UM PAR · AÇÕES COMUNITÁRIAS, P. 10

Para a pergunta sobre um canal entupido, a resposta orienta procurar a prefeitura. O JSONL registra o trecho da cartilha que atribui a limpeza à prefeitura.

Como conferir a entrega

O pacote inclui as entradas, os dados, a ferramenta local e a demonstração.

EXECUÇÃO LOCAL

```
python -m pip install -r requirements.txt
python fabrica.py gerar
python interface.py
```

Na interface, importe a ficha e veja a prévia anonimizada. Gere os quatro corpus com as fontes incluídas ou envie as cinco cópias oficiais. A instalação baixa as dependências. A geração trabalha offline, sem chave de API.

Dificuldades e escolhas

Os PDFs tinham cabeçalhos recorrentes, marcadores quebrados e palavras partidas. O NER confundiu siglas e títulos com nomes. A limpeza foi ajustada por fonte. O segmentador deixou 5 unidades fora por não conseguir acomodá-las no intervalo sem cortar seu conteúdo. PDFs apenas com imagem exigem OCR prévio.

Assistência na preparação

Modelo usado na elaboração: Codex (OpenAI, GPT-6). Síntese das instruções editoriais: redigir perguntas realistas e diálogos com duas trocas a partir dos trechos oficiais; preservar a evidência literal; encaminhar urgências e recusar fora do tema. A geração final é determinística. O CSV reúne 39 linhas para a revisão humana.

CANAIS NOS CASOS DE URGÊNCIA

192	193	199
SAMU	**Bombeiros**	**Defesa Civil**

Canais de referência do Ministério das Comunicações.

Demonstração no YouTube · youtu.be/rtItMzbgg9Q