FIAP / GLOBAL SOLUTION / 2º SEMESTRE DE 2026





# Fábrica de Corpus CitizenTech

Enchentes e deslizamentos
Da cartilha pública aos dados de treino e teste.

| 88 | 112 | 30 | 20 |
|---|---|---|---|
| TRECHOS | PARES QA | DIÁLOGOS | TESTES |


EQUIPE

Luiz Henrique Poss
Luis Filipe Chaves Amorim
Felipe Stefani Honorato

# Para quem é a fábrica?

O recorte vai do preparo comunitário à evacuação e aos cuidados depois da inundação.

## O problema de Joana

Joana é uma moradora fictícia de um bairro com córrego e encosta. Em dias de chuva, acessa a internet pelo celular e precisa decidir se deve se afastar, onde procurar orientação e a quem pedir socorro. As respostas devem caber em uma leitura rápida e indicar o próximo passo.

## ODS 11 · Meta 11.5

O projeto ajuda a tornar orientações sobre desastres ligados à água mais fáceis de localizar, com atenção a moradores de áreas vulneráveis. ONU Brasil.

### 05 FONTES PÚBLICAS

01 **Periferia sem risco**
Ministério das Cidades · Secretaria Nacional de Periferias · 2024 · Abrir fonte

02 **Cartilha para ações comunitárias de redução de risco**
Ministério das Cidades · Secretaria Nacional de Periferias · 2024 · Abrir fonte

03 **Cartilha de orientação no alerta de chuvas intensas**
Ministério da Saúde · 2017 · Abrir fonte

04 **Guia de preparação e resposta por inundação**
Ministério da Saúde · 2017 · Abrir fonte

05 **Canais de emergência**
Ministério das Comunicações · 2026-09-11 · Abrir fonte

103 páginas físicas em quatro PDFs e uma página HTML. A data é a da edição ou publicação. O manifesto guarda URLs, seções e hashes das cópias usadas.

# Da fonte ao JSONL

O Python reproduz a edição com documentos, âncoras e tokenizador locais.

01

## Ingerir

PDF, TXT, DOCX, HTML ou texto colado. Fontes novas, com metadados, entram no corpus de texto para consulta.

02

## Limpar

Remove margens repetidas, numeração, URLs soltas e artefatos gráficos. Une palavras quebradas no fim da linha.

03

## Normalizar e mascarar

Padroniza UTF-8/NFC, espaços e aspas. Aplica regex e NER também aos títulos e às seções.

04

## Segmentar

Reúne frases que atravessam páginas. Agrupa frases e parágrafos em 256 a 512 tokens do Qwen2.5-0.5B-Instruct.

05

## Ancorar e exportar

Busca o apoio literal nos documentos limpos, remove duplicatas e valida o teste congelado antes de exportar.

**FORMA SE TREINA. FATO SE CONSULTA.**

### Estável · comportamento

Escrever com clareza, usar o histórico e encaminhar quando falta informação. Categorias e conceitos gerais ajudam no vocabulário. O treino usa contexto de apoio para ligar a resposta ao documento.

### Volátil · consulta

Abrigos abertos, vagas, vias liberadas, alertas, horários, contatos locais e protocolos vigentes dependem da região e do momento. O RAG deve buscar uma fonte datada e consultar a autoridade atual quando necessário.

# O que sai dos dados

A mesma rotina usada nas fontes processa a ficha fictícia antes da exportação.

**01 / FICHA ORIGINAL**

```
Nome: Aurora de Papel Fictícia
CPF: 000.000.000-00
E-mail: aurora@exemplo.invalid
Telefone: +55 (00) 90000-0000
```

**02 / FICHA MASCARADA**

```
Nome: [NOME]
CPF: [CPF]
E-mail: [EMAIL]
Telefone: [TELEFONE]
```

O relato de orientação sobre chuva e a menção à Defesa Civil foram preservados. Os identificadores foram inventados para esta demonstração. A ficha fica fora dos quatro JSONL.

## Regras e exceções

Regex mascara CPF, e-mail e telefone. O rótulo ajuda a distinguir telefones compactos de CPFs. O spaCy identifica nomes, inclusive em títulos e seções. O manifesto lista exceções verificadas, como Defesa Civil, Fiocruz, Lei Maria da Penha, PNRS e Tétano.

## Minimização e guarda

O material vem de fontes oficiais. Capas com créditos, referências e dados de contato desnecessários são excluídos ou filtrados. A ferramenta não cria tabela de correspondência e descarta os uploads temporários. A evidência de antes e depois contém apenas a ficha sintética.

O reconhecimento de nomes pode errar, principalmente com siglas, nomes incomuns e leitura imperfeita de PDFs. Novas fontes exigem revisão de privacidade antes da publicação.

# O que a execução mostrou

A saída separa texto, perguntas e respostas, conversa e avaliação.

| Corpus | Exemplos | Tokens méd. | Duplicatas | Língua real |
|---|---|---|---|---|
| Texto puro | 88 | 293,0 | 0 | - |
| Perguntas e respostas | 112 | 78,8 | 0 | 56/112 |
| Conversacional | 30 | 285,5 | 0 | 30/60 |
| Teste separado | 20 | 46,2 | 0 | 10/20 |

Texto puro: 265 a 499 tokens. A média conta o conteúdo textual de cada formato. Cinco exemplos de cada corpus estão em **qualidade.json**. A taxa de língua real foi de 50% nos três conjuntos com perguntas.

## 20 de 20 pares fiéis na conferência assistida

A amostra de 20 pares foi comparada com os trechos de apoio na conferência assistida. As 112 âncoras também são validadas na geração. O grupo tem 39 linhas reservadas em revisao.csv e precisa registrar a revisão humana de pelo menos 33 exemplos.

## 13 diálogos de limite

Quatro recusas, quatro encaminhamentos e cinco urgências. Os 30 diálogos têm duas trocas e referências numeradas nos turnos com apoio. O teste tem 20 perguntas congeladas. O caso 15 ganhou uma fonte complementar. A comparação normalizada encontrou zero perguntas repetidas.

**EVIDÊNCIA DE UM PAR · AÇÕES COMUNITÁRIAS, P. 10**

Para a pergunta sobre um canal entupido, a resposta orienta procurar a prefeitura. O JSONL registra o trecho da cartilha que atribui a limpeza à prefeitura.

# Como conferir a entrega

O pacote inclui as entradas, os dados, a ferramenta local e a demonstração.

**EXECUÇÃO LOCAL**

```
python -m pip install -r requirements.txt
python fabrica.py gerar
python interface.py
```

A execução trabalha offline após a instalação. A interface aceita fontes novas com metadados e baixa um ZIP separado. As fontes novas entram no texto para RAG. Perguntas e diálogos mantêm a curadoria oficial.

## Dificuldades e escolhas

Os PDFs tinham cabeçalhos recorrentes e palavras partidas. O NER confundiu siglas e títulos com nomes. O segmentador deixou 5 unidades fora do intervalo. PDFs só com imagem exigem OCR prévio.

## Prompt editorial da revisão

Modelo de assistência editorial · Codex (OpenAI, GPT-6)

Revise os exemplos da Fábrica de Corpus CitizenTech sobre enchentes e deslizamentos. Use somente as fontes oficiais do manifesto. Compare cada resposta com seu trecho literal e amplie o contexto da passagem se ela depender de um título, de uma legenda ou de uma frase anterior. Preserve a linguagem informal das perguntas e deixe as respostas em português claro. Em cada turno com fatos ou orientação documentada, cite somente as evidências que sustentam aquele turno usando seus números. Nas recusas fora do tema, mantenha a fonte nula. Em urgência, dê a orientação imediata na primeira resposta e associe o encaminhamento à fonte oficial. Preserve literalmente as perguntas e os gabaritos do teste congelado. Registre correções de proveniência do teste separadamente. Aponte as mudanças feitas e deixe a decisão da revisão humana para os integrantes do grupo.

**CANAIS NOS CASOS DE URGÊNCIA**

| 192 | 193 | 199 |
|---|---|---|
| **SAMU** | **Bombeiros** | **Defesa Civil** |

Canais de referência do Ministério das Comunicações.

Demonstração no YouTube · youtu.be/rtItMzbgg9Q · execução original.